



Received 00th January 20xx
Accepted 00th February 20xx
Published 00th March 20xx

Open Access

DOI: 10.35472/x0xx0000

End to End Spoken Language Understanding Bahasa Indonesia Untuk Pencatatan Transaksi Ritel Berbasis CNN LSTM

Gymnastiar Al Khoarizmy¹, M. Deriansyah Okutra¹,
Mujadid Choirus Surya¹

¹Fakultas Sains, Institut Teknologi Sumatera

* Corresponding E-mail: gymnastiar.122450096@student.itera.ac.id

Abstract: Retail transaction recording in Indonesian SMEs is often performed manually, leading to inefficiency and errors. This study aims to develop an End-to-End Spoken Language Understanding (SLU) system for Indonesian retail transactions that directly extracts semantic information from speech signals. The proposed method employs a CNN-BiLSTM multi-task learning architecture using Log-Mel Spectrogram features and a hybrid dataset combining synthetic and manually recorded speech. A Two-Stage Training strategy is applied to improve model generalization. Experimental results show strong performance, achieving a macro-F1 score of up to 0.97 and balanced accuracy above 0.94, indicating the effectiveness of the proposed approach for voice-based retail transaction recording.

Keywords: *Spoken Language Understanding, End-to-End, CNN-BiLSTM, Retail Transactions, Indonesian Language*

Abstrak: Pencatatan transaksi ritel UMKM di Indonesia masih banyak dilakukan secara manual sehingga kurang efisien dan rentan kesalahan. Penelitian ini bertujuan mengembangkan sistem End-to-End Spoken Language Understanding (SLU) berbahasa Indonesia untuk mengekstraksi informasi transaksi langsung dari sinyal suara. Metode yang diusulkan menggunakan arsitektur CNN-BiLSTM multi-task learning dengan input Log-Mel Spectrogram dan dataset hibrida yang mengombinasikan data sintesis dan rekaman manual. Pelatihan dilakukan menggunakan strategi Two-Stage Training untuk meningkatkan generalisasi model. Hasil evaluasi menunjukkan bahwa model mampu mencapai performa tinggi dengan nilai macro-F1 score hingga 0,97 dan balanced accuracy di atas 0,94. Pendekatan ini menunjukkan potensi besar sebagai solusi pencatatan transaksi ritel berbasis suara yang efisien dan akurat.

Kata Kunci : *Spoken Language Understanding, End-to-End, CNN-BiLSTM, Transaksi Ritel, Bahasa Indonesia*

Pendahuluan

Sektor usaha ritel, khususnya Usaha Mikro, Kecil, dan Menengah (UMKM), memegang peranan vital dalam perekonomian Indonesia, namun proses digitalisasi operasionalnya masih menghadapi berbagai tantangan signifikan. Salah satu hambatan utama dalam transformasi digital UMKM adalah kurangnya literasi teknologi dan keterbatasan sumber daya manusia dalam mengoperasikan perangkat lunak pencatatan transaksi yang kompleks [1].

Pencatatan transaksi secara manual atau menggunakan antarmuka berbasis teks (ketikan) sering kali memakan waktu, rentan terhadap kesalahan manusia (*human error*), dan mengganggu efisiensi pelayanan pelanggan di kasir [2]. Oleh karena itu, diperlukan antarmuka yang lebih alami dan ergonomis, seperti penggunaan suara, untuk mempercepat proses input data transaksi tanpa mengharuskan kasir berinteraksi secara intensif dengan layar perangkat.

Teknologi yang memungkinkan komputer memahami maksud dari ucapan manusia dikenal sebagai *Spoken Language Understanding* (SLU). Dalam konteks ritel, SLU



bertujuan untuk mengekstrak informasi semantik seperti nama barang, jumlah, dan harga langsung dari sinyal suara [3]. Pendekatan konvensional dalam SLU umumnya menggunakan metode *pipeline* atau berjenjang, di mana sistem memisahkan proses *Automatic Speech Recognition* (ASR) untuk mengubah suara menjadi teks, dan *Natural Language Understanding* (NLU) untuk memahami teks tersebut. Namun, arsitektur terpisah ini memiliki kelemahan

mendasar berupa propagasi kesalahan (*error propagation*), di mana kesalahan transkripsi pada tahap ASR akan menyebabkan kegagalan fatal pada pemahaman maksud di tahap NLU [4]. Selain itu, sistem *pipeline* cenderung memiliki komputasi yang lebih berat dan latensi yang lebih tinggi karena proses yang bertingkat [5].

Untuk mengatasi kelemahan tersebut, pendekatan *End-to-End* (E2E) SLU dikembangkan untuk memetakan sinyal suara langsung ke slot semantik atau maksud (*intent*) tanpa perlu menghasilkan transkripsi teks perantara. Penelitian menunjukkan bahwa model E2E mampu mengurangi dampak kesalahan pengenalan kata dan lebih efisien dalam hal parameter model dibandingkan pendekatan *pipeline* tradisional [6]. Dalam implementasi arsitektur *deep learning* untuk pemrosesan suara, kombinasi *Convolutional Neural Network* (CNN) dan *Long Short-Term Memory* (LSTM) telah terbukti memberikan performa yang unggul. CNN memiliki kemampuan yang kuat dalam mengekstraksi fitur spasial dari spektrogram audio, sementara LSTM sangat efektif dalam memodelkan ketergantungan temporal jangka panjang pada data sekuensial seperti ucapan [7], [8].

Meskipun teknologi SLU berkembang pesat, sebagian besar penelitian masih berfokus pada Bahasa Inggris atau bahasa dengan sumber daya tinggi (*high-resource languages*), sedangkan penelitian untuk Bahasa Indonesia masih relatif terbatas dan menghadapi tantangan variabilitas pengucapan serta keterbatasan dataset publik [9]. Penerapan model *End-to-End* SLU khusus untuk domain transaksi ritel berbahasa Indonesia belum banyak dieksplorasi secara mendalam. Berdasarkan permasalahan dan peluang tersebut, penelitian ini mengusulkan pengembangan sistem *End-to-End Spoken Language Understanding* Bahasa Indonesia untuk pencatatan transaksi ritel berbasis arsitektur CNN-LSTM. Sistem ini diharapkan dapat memberikan solusi pencatatan yang akurat, efisien, dan tahan (*robust*) terhadap kesalahan, sehingga dapat mendukung percepatan digitalisasi pada sektor ritel di Indonesia

Method / Metode

A. Dataset

Penelitian ini menerapkan pendekatan dataset hibrida yang menggabungkan data sintetis dan data rekaman suara manusia asli untuk melatih sistem Spoken Language Understanding (SLU). Dataset utama terdiri dari 1.000 sampel audio yang dianotasi dengan label semantik meliputi *product* (jenis produk), *quantity* (jumlah barang), dan *intent* (maksud transaksi). Data sintetis dibuat menggunakan Google Text-to-Speech (TTS) sebanyak 550 sampel untuk memperkaya variasi kosakata, sedangkan data manual sebanyak 450 sampel dikumpulkan dari beberapa orang untuk menangkap karakteristik akustik natural. Seluruh berkas audio diproses ulang (*resampling*) menjadi frekuensi sampel 16.000 Hz dengan kanal mono menggunakan pustaka pemrosesan sinyal audio [10]. Untuk menghilangkan informasi yang tidak relevan, dilakukan pemangkasan (*trimming*) pada segmen hening di awal dan akhir sinyal audio dengan ambang batas intensitas suara sebesar 30 dB. Dataset dibagi menjadi 3 bagian yaitu *train*, *validation*, dan *test*.

B. Ekstraksi Fitur dan Augmentasi

Sinyal audio yang telah dibersihkan dikonversi menjadi representasi visual dua dimensi berupa *Log-Mel Spectrogram* sebagai input bagi jaringan saraf tiruan. Konfigurasi ekstraksi fitur menggunakan panjang jendela *Fast Fourier Transform* (FFT) sebesar 1024, panjang *hop* 256, dan jumlah filter Mel sebanyak 128 kanal [10]. Nilai spektrogram kemudian dinormalisasi ke dalam skala desibel (*power-to-db*) untuk menstabilkan distribusi data. Guna meningkatkan generalisasi model dan mencegah *overfitting* pada data latih yang terbatas, teknik augmentasi data diterapkan secara stokastik. Metode yang digunakan mengadopsi *SpecAugment* yang meliputi penopengan frekuensi (*frequency masking*) dengan parameter lebar 18 dan penopengan waktu (*time masking*) dengan parameter lebar 24 [10]. Selain itu, injeksi *Gaussian noise* dengan standar deviasi 0.05 dan pergeseran waktu (*time shifting*) turut diterapkan untuk mensimulasikan gangguan akustik pada lingkungan nyata.

C. Arsitektur Model Hibrida CNN-BiLSTM

Sistem yang diusulkan mengimplementasikan arsitektur *Multi-Task Learning* yang mengintegrasikan *Convolutional Neural Network* (CNN) dan *Bidirectional Long Short-Term Memory* (BiLSTM). Bagian enkoder menggunakan tiga blok konvolusi (*ConvBlock*) untuk mengekstraksi fitur spasial lokal dari spektrogram, di mana setiap blok terdiri dari lapisan

Konvolusi 2D, *Batch Normalization*, aktivasi ReLU, *Max Pooling*, dan *Dropout* sebesar 0.2. Fitur hasil konvolusi diproyeksikan dan diproses oleh lapisan BiLSTM untuk menangkap ketergantungan temporal jangka panjang dari sinyal ucapan secara dua arah. Keluaran dari lapisan rekurensi ini didistribusikan ke tiga *head* klasifikasi terpisah yang masing-masing memprediksi kelas produk, kuantitas, dan *intent* menggunakan lapisan *Linear*, *Layer Normalization*, dan *Dropout* sebesar 0.3.

D. Strategi Pelatihan

Pelatihan model dilakukan dalam dua tahap utama (*Two-Stage Training*) untuk mengatasi ketidakseimbangan jumlah sampel antara data sintetis dan manual. Tahap pertama (*Mixed Training*) melatih model menggunakan gabungan seluruh data dengan menerapkan *Weighted Random Sampler* untuk melakukan *oversampling* pada data manual, memastikan model tidak bias terhadap pola suara sintetis. Tahap kedua (*Fine-Tuning*) dilakukan dengan melatih ulang model hasil tahap pertama hanya menggunakan data manual dengan laju pembelajaran (*learning rate*) yang direduksi untuk adaptasi domain yang lebih spesifik. Optimasi parameter dilakukan menggunakan algoritma AdamW dengan mekanisme peluruhan bobot (*weight decay*) untuk regularisasi [11].

Setelah proses *fine-tuning*, dilakukan *hyperparameter tuning* untuk menyempurnakan konfigurasi pelatihan model. Proses ini difokuskan pada evaluasi beberapa kombinasi *learning rate* dan ukuran *batch* melalui pendekatan *grid search* terbatas dengan tujuan memperoleh keseimbangan optimal antara stabilitas pelatihan dan kemampuan generalisasi model. Konfigurasi terbaik yang diperoleh dari tahap ini selanjutnya digunakan sebagai pengaturan akhir model dalam proses evaluasi, sehingga performa yang dihasilkan merepresentasikan kondisi pelatihan yang paling optimal pada data rekaman manual.

E. Evaluasi Kinerja dan Metrik


TAMBAHAIN

Results And Discussion


A. CNN-BiLSTM

Kinerja model CNN-BiLSTM *multi-task learning* yang diusulkan dievaluasi menggunakan dataset gabungan yang terdiri atas data audio sintetis hasil Google Text-to-Speech dan data rekaman manual. Evaluasi difokuskan pada tiga target prediksi, yaitu klasifikasi produk, klasifikasi jumlah (*quantity*), dan deteksi *intent*, yang seluruhnya dilatih secara bersamaan dalam satu kerangka pembelajaran *multi-task*. Metrik evaluasi yang digunakan meliputi *balanced accuracy* dan *macro-F1 score* guna memberikan penilaian performa yang adil terhadap distribusi kelas yang ada.

Hasil pelatihan pada tahap pertama, yang memanfaatkan data campuran sintetis dan manual dengan penerapan *oversampling* pada data manual, menunjukkan peningkatan performa yang konsisten seiring bertambahnya jumlah epoch. Nilai *macro-F1 score* untuk tugas klasifikasi produk meningkat secara bertahap hingga mencapai nilai terbaik sebesar 0,9788 pada data validasi. Pada saat yang sama, nilai *balanced accuracy* untuk klasifikasi produk melampaui 0,96, sedangkan *balanced accuracy* untuk klasifikasi jumlah juga mencapai nilai di atas 0,95. Hasil ini mengindikasikan bahwa arsitektur CNN-BiLSTM mampu mempelajari karakteristik spektral dan temporal sinyal suara secara efektif ketika didukung oleh jumlah data latih yang besar dan beragam.



Untuk meningkatkan kesesuaian model terhadap kondisi data nyata, dilakukan pelatihan tahap kedua berupa *fine-tuning* menggunakan data rekaman manual saja. Pada tahap ini, *learning rate* diturunkan menjadi 1×10^{-4} untuk menjaga stabilitas proses pembaruan parameter, dan augmentasi data dinonaktifkan agar karakteristik asli data manual tetap terjaga. Hasil *fine-tuning* menunjukkan bahwa model tetap mempertahankan performa yang tinggi dengan nilai *macro-F1 score* terbaik sebesar 0,9689 pada data validasi. Nilai *balanced accuracy* untuk klasifikasi produk berada di atas 0,94, sedangkan untuk klasifikasi jumlah berada pada kisaran 0,89 hingga 0,92.



Meskipun nilai *macro-F1 score* pada tahap *fine-tuning* sedikit lebih rendah dibandingkan hasil terbaik pada tahap pertama, perbedaan ini dapat dijelaskan oleh ukuran dataset manual yang lebih terbatas. Fenomena serupa juga dilaporkan dalam penelitian sebelumnya oleh Tremblay *et al*, di mana pelatihan awal menggunakan data sintetis atau data teraugmentasi berskala besar mampu menghasilkan performa tinggi, sementara *fine-tuning* pada data nyata berfungsi meningkatkan robustitas dan kemampuan generalisasi model, meskipun dengan penurunan performa yang relatif kecil [12].

B. Hyperparameter Tunning

Proses *hyperparameter tuning* dilakukan untuk memperoleh konfigurasi parameter pelatihan yang optimal sebelum model ditetapkan sebagai model akhir. Tahapan ini dirancang secara bertahap agar selaras dengan strategi pelatihan dua tahap yang telah diterapkan, yaitu dengan memisahkan proses penyesuaian hyperparameter pada data campuran dan penyesuaian lanjutan pada data manual.

<i>bs</i>	<i>lr</i>	<i>weight</i>	<i>macro f1 score</i>
8	0.0001	5	0.960995
8	0.0001	3	0.958846
8	0.0003	5	0.822532
8	0.0003	3	0.917532
16	0.0001	5	0.917532
16	0.0001	3	0.591294
16	0.0003	5	0.923131
16	0.0003	3	0.912540

Berdasarkan eksperimen *grid search* terbatas yang dilakukan pada tahap pertama (*Mixed Training*), diperoleh hasil evaluasi performa model menggunakan metrik *Macro F1 Score* sebagaimana disajikan pada Tabel [Nomor Tabel]. Eksperimen ini melibatkan kombinasi tiga parameter utama: ukuran *batch* (*bs*), laju pembelajaran (*lr*), dan bobot penyeimbang kelas (*weight*) yang diaplikasikan pada *Weighted Random Sampler*.

Hasil menunjukkan bahwa konfigurasi *batch size* 8, *Learning Rate* 0.0001, dan *Weight* 5 menghasilkan performa tertinggi dengan *Macro F1 Score* mencapai **0.9609**. Nilai ini mengindikasikan bahwa model mampu mempelajari representasi fitur dari gabungan data sintetis dan manual dengan sangat baik pada konfigurasi tersebut.

Secara umum, terlihat pola bahwa penggunaan bobot (*weight*) yang lebih besar (nilai 5) cenderung memberikan skor F1 yang lebih tinggi atau stabil dibandingkan bobot yang lebih kecil (nilai 3). Hal ini mengonfirmasi hipotesis awal bahwa pemberian bobot lebih besar pada sampel data manual (minoritas) melalui *Weighted Random Sampler* krusial untuk mencegah bias model terhadap data sintetis. Sebagai contoh, pada *batch size* 16 dan *learning rate* 0.0001, penggunaan *weight* 3 menyebabkan penurunan performa drastis hingga 0.5912, sedangkan *weight* 5 mampu mempertahankan performa di angka 0.9175.

Selanjutnya, tahap kedua difokuskan pada penyesuaian lanjutan terhadap model terbaik hasil *hyperparameter* tahap pertama dengan menggunakan data rekaman manual saja.

<i>bs</i>	<i>lr</i>	<i>epoch</i>	<i>macro f1 score</i>
8	0.00005	6	0.979798
8	0.00005	8	0.961616
8	0.00005	10	0.979798
8	0.00010	6	0.957576
8	0.00010	8	0.979798
8	0.00010	10	0.932820

Secara keseluruhan, proses *fine-tuning* terbukti berhasil meningkatkan performa model secara signifikan dibandingkan tahap pertama. Nilai *Macro F1 Score* tertinggi meningkat dari 0.9609 (Stage-1) menjadi **0.9798** (Stage-2). Peningkatan ini mengindikasikan bahwa model berhasil menyesuaikan bobotnya terhadap karakteristik unik data suara manual yang lebih natural dan beragam dibandingkan data sintetis.

Berdasarkan hasil eksperimen, konfigurasi dengan *Learning Rate* 0.00005 dan *Epoch* 6 dinilai sebagai pengaturan paling efisien dan stabil. Meskipun nilai F1 tertinggi (0.9798) tercapai pada tiga kondisi berbeda (LR 0.00005 pada epoch 6 dan 10, serta LR 0.00010 pada epoch 8), penggunaan *learning rate* 0.00010 menunjukkan ketidakstabilan menjelang akhir pelatihan. Hal ini terlihat pada penurunan drastis skor F1 menjadi 0.9328 pada epoch ke-10 untuk LR 0.00010, yang mengindikasikan terjadinya *overfitting*. Sebaliknya, LR 0.00005 menunjukkan performa yang lebih konsisten dan mampu mencapai performa puncak (0.9798).

lebih awal pada epoch ke-6, sehingga dipilih untuk efisiensi komputasi.

Conclusions / Kesimpulan

Penelitian ini berhasil mengembangkan sistem End-to-End Spoken Language Understanding (SLU) berbasis CNN-BiLSTM multi-task learning untuk pencatatan transaksi ritel berbahasa Indonesia. Pendekatan end-to-end memungkinkan sistem mengekstraksi informasi semantik berupa produk, kuantitas, dan intent secara langsung dari sinyal suara tanpa ketergantungan pada transkripsi teks perantara, sehingga mengurangi risiko propagasi kesalahan yang umum terjadi pada arsitektur pipeline konvensional.

Pemanfaatan dataset hibrida yang menggabungkan data sintesis dan rekaman manual, serta penerapan teknik augmentasi audio, terbukti mampu meningkatkan variasi data latih dan stabilitas proses pelatihan. Selain itu, strategi Two-Stage Training memberikan kontribusi signifikan dalam meningkatkan kemampuan generalisasi model pada data rekaman manual yang merepresentasikan kondisi penggunaan nyata.

Hasil evaluasi menunjukkan bahwa model mampu mencapai performa yang tinggi dan konsisten pada seluruh tugas prediksi, menegaskan efektivitas integrasi CNN dalam mengekstraksi fitur spektral dan BiLSTM dalam memodelkan ketergantungan temporal sinyal ucapan. Secara keseluruhan, sistem yang diusulkan memiliki potensi kuat untuk diterapkan sebagai solusi pencatatan transaksi ritel berbasis suara yang efisien, akurat, dan mudah digunakan, serta dapat mendukung percepatan digitalisasi UMKM di Indonesia.

Conflicts of interest

In accordance with our policy on [Conflicts of interest](#) please ensure that a conflicts of interest statement is included in your manuscript here. Please note that this statement is required for all submitted manuscripts. If no conflicts exist, please state that "There are no conflicts to declare".

Acknowledgements

The acknowledgements come at the end of an article after the conclusions and before the references.

References

- [1] T. Fitarti dan L. Hartati, "Laporan Survei UMKM: Tantangan dan Peluang bagi UMKM di Indonesia," *Bank Indonesia*, 2022.
- [2] I. A. Lestari, "Pencatatan Keuangan Digital UMKM Menggunakan Aplikasi Krealogi," *Abdima Jurnal Pengabdian Mahasiswa*, vol. 2, no. 2, hal. 6523–6529, 2023.
- [3] S. Mdhaftar, M. Plantive, dan Y. Estève, "End-to-End Spoken Language Understanding: A Survey," *IEEE Access*, vol. 10, hal. 103045-103068, 2022.
- [4] E. Serdyuk dkk., "Towards End-to-End Spoken Language Understanding," dalam *Proc. IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, Calgary, AB, Canada, 2018, hal. 5754-5758.
- [5] Y. Wang dkk., "A Streaming End-to-End Framework For Spoken Language Understanding," dalam *Proc. International Joint Conference on Artificial Intelligence (IJCAI)*, 2021, hal. 3921-3927.
- [6] M. Haghani dkk., "From Audio to Semantics: Approaches to End-to-End Spoken Language Understanding," dalam *Proc. IEEE Spoken Language Technology Workshop (SLT)*, Athena, Yunani, 2018, hal. 720-726.
- [7] S. Dutta, "Speech Emotion Recognition: Comparative Analysis of CNN-LSTM and Attention-Enhanced CNN-LSTM Models," *MDPI Acoustics*, vol. 6, no. 2, hal. 345-360, 2024.
- [8] X. Mou dkk., "Speech Emotion Recognition Based on CNN+LSTM Model," dalam *Proc. ROCLING Conference on Computational Linguistics*, 2021, hal. 43-47.
- [9] D. P. Lestari, "Enhancing Indonesian Automatic Speech Recognition: Evaluating Multilingual Models with Diverse Speech Variabilities," *arXiv preprint arXiv:2410.08828*, 2024.
- [10] B. McFee et al., "librosa: Audio and music signal analysis in python," dalam *Proceedings of the 14th Python in Science Conference*, 2015, vol. 8, hal. 18–25.
- [11] I. Loshchilov dan F. Hutter, "Decoupled Weight Decay Regularization," dalam *International Conference on Learning Representations (ICLR)*, 2019.
- [12] J. Tremblay et al., "Training deep networks with synthetic data: Bridging the reality gap by domain randomization," in *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, Salt Lake City, UT, USA, 2018, pp. 969–977.